



**AGH**

Akademia Górniczo-Hutnicza  
im. Stanisława Staszica  
w Krakowie

---

Praca licencjacka

# Testowanie regresji liniowej przeciwko regresji wypukłej

Grzegorz Mika

Kierunek: Matematyka

Nr albumu: 267543

Promotor  
dr Konrad Nosek



Wydział Matematyki Stosowanej

---

Kraków 2016

## Oświadczenie autora

*Ja, niżej podpisany Grzegorz Mika oświadczam, że praca ta została napisana samodzielnie i wykorzystywała (poza zdobytą na studiach wiedzę) jedynie wyniki prac zamieszczonych w spisie literatury.*

.....

(Podpis autora)

## Oświadczenie promotora

*Oświadczam, że praca spełnia wymogi stawiane pracom licencjackim.*

.....

(Podpis promotora)

# Spis treści

Wstęp	2
1 Stożki wypukłe	2
2 Regresja wypukła	4
3 Statystyka testowa i jej rozkład	9
3.1 Lematy i oznaczenia . . . . .	9
3.2 Statystyka testowa . . . . .	11
4 Podsumowanie	14
Bibliografia	16

Rozważmy problem dopasowania pewnej funkcji  $f$  opisującej związek między zmiennymi objaśniającymi  $x_i$  a zmiennymi objaśnianymi  $y_i$  według następującego modelu

$$y_i = f(x_i) + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

gdzie zakładamy, że błędy  $\varepsilon_i$  są niezależnymi zmiennymi losowymi o tym samym rozkładzie normalnym  $N(0, \sigma^2)$ . Punkty  $x_i$  są ustalone. Ponadto zakładamy, że wariancja  $\sigma^2$  jest znana.

Najprostszym związkiem między obserwacjami  $x_i$  a odpowiedziami  $y_i$  jest zależność liniowa. Możliwy jest jednak również inna zależność między obserwacjami a odpowiedziami. W niniejszej pracy rozważać będziemy problem, czy funkcja  $f$  jest funkcją liniową czy pewną funkcją wypukłą. Prowadzi do problemu testowania hipotez.

$$H_0: f(x) = ax + b \quad vs. \quad H_1: f \in \mathcal{F},$$

gdzie  $\mathcal{F}$  jest klasą funkcji wypukłych.

W niniejszej pracy postaramy się skonstruować odpowiedni do postawionego problemu test statystyczny. Zaproponowane zostanie rozwiązanie oparte o iloraz wiarogodności w przypadku modelu regresji z ograniczeniami w postaci nierówności.

W pierwszym rozdziale zostaną omówione podstawowe własności wielościenne stożków wypukłych traktowanych jako podzbiór przestrzeni liniowej. Drugi rozdział będzie traktował o konstrukcji estymatora regresji wypukłej jako rzutu wektora danych na taki stożek wielościenne. W trzecim rozdziale zostanie wyznaczony rozkład poszukiwanej statystyki testowej w przypadku ze znaną wariancją błędu obserwacji.

Praca została napisana głównie na podstawie [2], natomiast rozdział o wyznaczaniu estymatora regresji wypukłej został napisany w dużym stopniu na podstawie [1].

## 1 Stożki wypukłe

Do konstrukcji testu zostanie wykorzystana metoda rzutowania wektora danych na stożek wielościenne powstały w wyniku narzuconych ograniczeń liniowych. W tym rozdziale zostaną przedstawione podstawowe definicje i własności wypukłych stożków wielościenne użyteczne w dalszych rozważaniach.

**Definicja 1 (Ortant).** <sup>1</sup> *Ortantem w  $n$ -wymiarowej przestrzeni  $\mathbb{R}^n$  nazywamy podzbiór powstały przez ograniczenie każdej ze współrzędnych do bycia nieujemną*

---

<sup>1</sup>Definicja podana za Wikipedią: <https://en.m.wikipedia.org/wiki/Orthant>

albo niedodatnią, czyli

$$O = \{(x_1, x_2, \dots, x_n) \in \mathbb{R}^n : \epsilon_i x_i \geq 0, |\epsilon_i| = 1, i = 1, 2, \dots, n\}$$

**Definicja 2 (Nieujemny ortant).** Nieujemnym ortantem nazywamy ortant, którego wszystkie współrzędne są nieujemne.

**Definicja 3 (Półprzestrzeń).** Półprzestrzenią  $H$  przestrzeni wektorowej  $\mathbb{R}^n$  nazywamy zbiór

$$H = \{(x_1, x_2, \dots, x_n) \in \mathbb{R}^n : a_1 x_1 + a_2 x_2 + \dots + a_n x_n \geq 0\}$$

gdzie  $a_1, a_2, \dots, a_n$  są pewnymi, ustalonymi liczbami rzeczywistymi.

**Definicja 4 (Wielościenny stożek wypukły).** Wielościennym stożkiem wypukłym w przestrzeni wektorowej  $\mathbb{R}^n$  nazywamy przecięcie skończonej ilości półprzestrzeni przestrzeni  $\mathbb{R}^n$ .

Z powyższych definicji wynika, że dowolny stożek wypukły  $K$  w przestrzeni wektorowej  $\mathbb{R}^n$  można zapisać jako

$$K = \bigcap_{i=1}^m H_i,$$

gdzie

$$H_j = \{\mathbf{x} \in \mathbb{R}^n : \sum_{i=1}^n a_i^j x_i \geq 0\}.$$

Zatem stożek  $K$  możemy przedstawić w postaci

$$K = \left\{ (x_1, x_2, \dots, x_n) \in \mathbb{R}^n : \sum_{i=1}^n a_i^1 x_i \geq 0, \dots, \sum_{i=1}^n a_i^m x_i \geq 0 \right\}$$

co będziemy zapisywać skrótowo jako

$$K = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{A}\mathbf{x} \geq \mathbf{0}\},$$

gdzie

$$\mathbf{A} = \begin{bmatrix} a_1^1 & a_2^1 & \dots & a_n^1 \\ a_1^2 & a_2^2 & \dots & a_n^2 \\ \vdots & \vdots & \dots & \vdots \\ a_1^m & a_2^m & \dots & a_n^m \end{bmatrix}, \quad \mathbf{x} = (x_1, x_2, \dots, x_n)^T.$$

Symbolem  $\langle \cdot, \cdot \rangle$  będziemy oznaczać iloczyn skalarny w przestrzeni wektorowej  $V$ . Oznaczmy ponadto przez  $\gamma_i^T$  kolejne wiersze macierzy  $-\mathbf{A}$ . Bez straty ogólności

możemy założyć, że tworzą one układ wektorów liniowo niezależnych, gdyż w przeciwnym wypadku któreś ograniczenie stanowiłoby kombinację pozostałych a stąd dostajemy, że  $m \leq n$ . Wtedy stożek  $K$  możemy też zapisać w sposób

$$K = \{\mathbf{x} \in \mathbb{R}^n : \langle \mathbf{x}, \boldsymbol{\gamma}_i \rangle \leq 0, i = 1, 2, \dots, m\}.$$

Zbiór wektorów  $\{\boldsymbol{\gamma}_i\}_{i=1}^m$  możemy uzupełnić do bazy przestrzeni  $\mathbb{R}^n$  o wektory ortogonalne do wektorów z tego zbioru oraz zdefiniować bazę dualną złożoną z wektorów  $\boldsymbol{\beta}_i$  w następujący sposób

$$\boldsymbol{\beta}_i^T \boldsymbol{\gamma}_j = \begin{cases} -1, & i = j \\ 0, & i \neq j \end{cases}. \quad (1.1)$$

Wówczas możemy zapisać równoważne przedstawienie stożka  $K$

$$K = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{x} = \sum_{i=1}^m b_i \boldsymbol{\beta}_i + \sum_{i=m+1}^n c_i \boldsymbol{\beta}_i, b_i \geq 0, c_i \in \mathbb{R}\}.$$

**Twierdzenie 1.** Niech  $\{\boldsymbol{\gamma}_i\}_{i=1}^n, \{\boldsymbol{\beta}_i\}_{i=1}^n$  będą bazami przestrzeni  $\mathbb{R}^n$  takimi, że  $\boldsymbol{\beta}_i^T \boldsymbol{\gamma}_i = -1$  oraz  $\boldsymbol{\beta}_i^T \boldsymbol{\gamma}_j = 0$  dla  $i \neq j$ . Wtedy przedstawienia

$$K = \{\mathbf{x} \in \mathbb{R}^n : \langle \mathbf{x}, \boldsymbol{\gamma}_i \rangle \leq 0, \quad i = 1, 2, \dots, m\}$$

$$K = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{x} = \sum_{i=1}^m b_i \boldsymbol{\beta}_i + \sum_{i=m+1}^n c_i \boldsymbol{\beta}_i, \quad b_i \geq 0, c_i \in \mathbb{R}\}$$

są równoważne.

*Dowód.* Wektory  $\boldsymbol{\beta}_i, \boldsymbol{\gamma}_i, i = 1, 2, \dots, n$  spełniają zależność  $\boldsymbol{\beta}_i^T \boldsymbol{\gamma}_i = -1$  oraz  $\boldsymbol{\beta}_i^T \boldsymbol{\gamma}_j = 0, i \neq j$ . Oznaczając przez  $\mathbf{B}, \mathbf{C}$  macierze, których kolumnami są odpowiednio wektory  $\boldsymbol{\beta}_i, \boldsymbol{\gamma}_i$ , związek ten możemy przedstawić jako  $\mathbf{B}^T \mathbf{C} = -\mathbf{I}$ . Macierz  $\mathbf{B}$  jest nieosobliwa i jest macierzą przejścia z bazy kanonicznej do bazy  $\{\boldsymbol{\beta}_i\}_{i=1}^n$ . Stąd dostajemy, że  $\mathbf{C}^T \mathbf{x} = -\mathbf{B}^{-1} \mathbf{x}$ . Wyrażenia  $\langle \mathbf{x}, \boldsymbol{\gamma}_i \rangle, i = 1, 2, \dots, m$  są pierwszymi  $m$  współrzędnymi  $\mathbf{C}^T \mathbf{x}$ . Zatem wektor  $\mathbf{x}$  wyrażony w bazie złożonej z wektorów  $\boldsymbol{\beta}_i$  ma pierwsze  $m$  współrzędnych nieujemnych wtedy i tylko wtedy, gdy  $\langle \mathbf{x}, \boldsymbol{\gamma}_i \rangle \leq 0, i = 1, 2, \dots, m$ , co dowodzi równoważności przedstawień.  $\square$

## 2 Regresja wypukła

Podobnie jak w przypadku estymatora regresji liniowej wyznaczonego metodą najmniejszych kwadratów, który jest rzutem wektora danych na pewną podprzestrzeń liniową, tak w przypadku estymatora regresji wypukłej, który wyznaczymy

tą samą metodą, będzie on rzutem na pewien wielościenny stożek wypukły powstały w wyniku stosownych ograniczeń.

Zbiór po którym będziemy minimalizować kwadrat błędu powstaje w sposób następujący. Przypuśćmy, że wartości  $x_i$   $i = 1, 2, \dots, n$  są różne między sobą i uporządkowane rosnąco oraz niech  $\theta_i = f(x_i)$ ,  $i = 1, 2, \dots, n$ . Wymóg wypukłości funkcji  $f$  może zostać zapisany jako

$$\frac{\theta_{i+1} - \theta_i}{x_{i+1} - x_i} \leq \frac{\theta_{i+2} - \theta_{i+1}}{x_{i+2} - x_{i+1}}, \quad i = 1, 2, \dots, n-2,$$

czyli by spadki wartości funkcji  $f$  między kolejnymi punktami  $x_i$  były niemalejące. Warunek ten można przekształcić do postaci

$$\theta_i(x_{i+2} - x_{i+1}) - \theta_{i+1}(x_{i+2} - x_i) + \theta_{i+2}(x_{i+1} - x_i) \geq 0, i = 1, \dots, n-2$$

Zgodnie z rozważaniami przeprowadzonymi w poprzednim paragrafie możemy zbiór tych ograniczeń zapisać jako

$$K = \{\mathbf{A}\theta \geq 0\}$$

gdzie  $\mathbf{A}$  jest rzeczywistą macierzą wymiaru  $(n-2) \times n$ , której kolejne wiersze stanowią współczynniki przy niewiadomych  $\theta_1, \dots, \theta_n$  wzięte z kolejnych ograniczeń. Oznaczając przez  $\Delta_i = x_{i+1} - x_i$  macierz  $\mathbf{A}$  przyjmuje następującą postać

$$\begin{bmatrix} \Delta_2 & -\Delta_2 - \Delta_1 & \Delta_1 & 0 & 0 \dots & 0 \\ 0 & \Delta_3 & -\Delta_3 - \Delta_2 & \Delta_2 & 0 \dots & 0 \\ & \vdots & \ddots & & & \vdots \\ 0 & \dots & \Delta_{i+1} & -\Delta_{i+1} - \Delta_i & \Delta_i & \dots & 0 \\ & \vdots & & \ddots & & & \vdots \\ 0 & 0 & 0 & \dots & \Delta_{n-1} & -\Delta_{n-1} - \Delta_{n-2} & \Delta_{n-2} \end{bmatrix}.$$

Zatem problem znalezienia estymatora regresji wypukłej sprowadza się do znalezienia  $\hat{\theta} \in K$  takiego, że

$$\min_{\theta \in K} \|\mathbf{y} - \theta\| = \|\mathbf{y} - \hat{\theta}\|,$$

gdzie  $\|\mathbf{x}\| = \sqrt{\mathbf{x}^T \mathbf{x}}$ .

Niech  $B = (\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n)$  oznacza bazę kanoniczną przestrzeni  $\mathbb{R}^n$ . Oznaczmy przez  $\gamma_i = -\mathbf{A}^T \mathbf{e}_i$ ,  $i = 1, 2, \dots, n-2$ . Wtedy zbiór  $K$  możemy zapisać jako  $K = \{\theta \in \mathbb{R}^n: -\mathbf{e}_i^T \mathbf{A}\theta \leq 0, i = 1, 2, \dots, n-2\} = \{\theta \in \mathbb{R}^k: \langle \gamma_i, \theta \rangle \leq 0, i = 1, 2, \dots, n-2\}$ .

Z określenia macierzy  $\mathbf{A}$  oraz wektorów  $\gamma_i$ ,  $i = 1, 2, \dots, n-2$ , widać, że tworzą one układ wektorów liniowo niezależnych. Zatem zbiór  $B'_\gamma = \{\gamma_i, i = 1, 2, \dots, n-2\}$

można uzupełnić do bazy  $B_\gamma$  przestrzeni  $\mathbb{R}^n$  o wektory  $\gamma_{n-1}, \gamma_n$  tak, żeby były one ortogonalne do wszystkich wektorów z bazy  $B'_\gamma$ . Sprawdzimy, że warunek ten spełniają wektory  $\gamma_{n-1} = \mathbf{1}$  oraz  $\gamma_n = (\mathbf{x} - \bar{x}\mathbf{1})$ , gdzie  $\mathbf{x} = (x_1, x_2, \dots, x_n)$ ,  $\bar{x}$  oznacza wartość średnią,  $\mathbf{1} = (1, 1, \dots, 1)^T$ , a ortogonalność rozumiana jest w sensie iloczynu skalarnego powiązanego ze zdefiniowaną wcześniej normą euklidesową.

**Lemat 1.** *Wektory  $\gamma_{n-1}, \gamma_n$  zdefiniowane jak powyżej są ortogonalne do wektorów ze zbioru  $B'_\gamma$ .*

*Dowód.* Dowolny wektor ze zbioru  $B'_\gamma$  możemy zapisać jako

$$\gamma_i = (0, \dots, 0, \overset{(i)}{x_{i+1} - x_{i+2}}, \overset{(i+1)}{x_{i+2} - x_i}, \overset{(i+2)}{x_i - x_{i+1}}, 0, \dots, 0). \text{ Stąd } \langle \mathbf{1}, \gamma_i \rangle = x_{i+1} - x_{i+2} + x_{i+2} - x_i + x_i - x_{i+1} = 0 \text{ oraz } \langle \mathbf{x} - \bar{x}\mathbf{1}, \gamma_i \rangle = \langle \mathbf{x}, \gamma_i \rangle - \bar{x} \langle \mathbf{1}, \gamma_i \rangle = x_i(x_{i+1} - x_{i+2}) + x_{i+1}(x_{i+2} - x_i) + x_{i+2}(x_i - x_{i+1}) = 0. \quad \square$$

Teraz możemy zdefiniować bazę  $B_\beta = \{\beta_1, \beta_2, \dots, \beta_n\}$  dualną do bazy  $B_\gamma$  w zaproponowany w poprzednim paragrafie sposób (por. (1.1))

$$\beta_i^T \gamma_j = \begin{cases} -1, & i = j \\ 0, & i \neq j \end{cases}.$$

Oznaczając przez  $\mathbf{B}$  i  $\mathbf{C}$  macierze, których kolumnami są odpowiednio wektory  $\beta_i$  i  $\gamma_i$  związek między nimi możemy wyrazić jako

$$\mathbf{B}^T \mathbf{C} = -\mathbf{I},$$

gdzie  $\mathbf{I}$  oznacza macierz jednostkową.

Niech  $E$  oznacza podprzestrzeń przestrzeni  $\mathbb{R}^n$  rozpiętą przez wektory  $\beta_{n-1}, \beta_n$ , natomiast  $\mathcal{L}(K)$  oznacza przestrzeń rozpiętą przez wektory  $\beta_i, i = 1, 2, \dots, n-2$ . Przestrzeń  $E$  oraz  $\mathcal{L}(K)$  są do siebie ortogonalne, zatem wektor obserwacji  $\mathbf{y}$  możemy zapisać jako sumę  $\mathbf{y}_E + \mathbf{z}$ , gdzie  $\mathbf{y}_E$  i  $\mathbf{z}$  są rzutami wektora  $\mathbf{y}$  odpowiednio na podprzestrzeń  $E$  oraz  $\mathcal{L}(K)$ .

**Przykład 1.** *Prześledźmy powyższe rozważania na przykładzie. Rozważmy zbiór danych  $\{x_1, x_2, x_3, x_4\}$  takich, że  $x_{i+1} - x_i = 1, i = 1, 2, 3$ .*

*Macierz ograniczeń  $\mathbf{A}$  przybiera wtedy postać*

$$\mathbf{A} = \begin{bmatrix} 1 & -2 & 1 & 0 \\ 0 & 1 & -2 & 1 \end{bmatrix}.$$

*Zatem stożek powstały z ograniczeń jest postaci*

$$K = \{\boldsymbol{\theta} \in \mathbb{R}^4: \begin{bmatrix} 1 & -2 & 1 & 0 \\ 0 & 1 & -2 & 1 \end{bmatrix} \boldsymbol{\theta} \geq 0\}.$$



Baza wektorów  $B_{\gamma}$  jest postaci

$$B_{\gamma} = \left( (-1, 2, -1, 0)^T, (0, -1, 2, -1)^T, (1, 1, 1, 1)^T, \left( -\frac{3}{2}, -\frac{1}{2}, \frac{1}{2}, \frac{3}{2} \right)^T \right).$$

Wektory  $\beta_i$  spełniające warunek  $\langle \beta_i, \gamma_i \rangle = -1$  oraz  $\langle \beta_i, \gamma_j \rangle = 0, i \neq j$  mają następującą postać

$$B_{\beta} = ((3, -4, -1, 2)^T, (2, -1, -4, 3)^T, (-1, -1, -1, -1)^T, (3, 1, -1, -3)^T).$$

Przestrzeń na które będziemy rzutować wektor obserwacji przybierają postać

$$E = \{t_1(-1, -1, -1, 1) + t_2(3, 1, -1, -3), t_1, t_2 \in \mathbb{R}\}$$

$$\mathcal{L}(K) = \{t_1(3, -4, -1, 2) + t_2(2, -1, -4, 3), t_1, t_2 \in \mathbb{R}\}. \quad \diamond$$

Zadanie znalezienia rzutu wektora obserwacji na stożek  $K$  sprowadza się do znalezienia rzutu jego składowych na stożek  $K$ . Wszystkie elementy podprzestrzeni  $E$  należą do stożka  $K$ , więc rzut wektora  $\mathbf{y}_E$  na stożek  $K$  jest tym samym co jego rzut na podprzestrzeń  $E$ . Przestrzeń  $E$  jest rozpinana przez wektory  $\beta_{n-1}$  i  $\beta_n$ . Niech  $\mathcal{E}$  oznacza macierz wymiaru  $n \times 2$  taką, że jej kolumnami są wektory rozpinające podprzestrzeń  $E$ . Wtedy rzut wektora  $\mathbf{y}$  na tę podprzestrzeń wyraża się wzorem

$$\mathbf{y}_E = \mathcal{E}(\mathcal{E}^T \mathcal{E})^{-1} \mathcal{E}^T \mathbf{y}. \quad (2.1)$$

Pozostaje zagadnienie znalezienia rzutu  $\mathbf{z}$  na stożek  $K$ . Sprowadza się ono do znalezienia rzutu  $\mathbf{z}$  na stożek

$$K' = K \cap \mathcal{L}(K) = \{\boldsymbol{\theta} \in \mathbb{R}^n : \boldsymbol{\theta} = \sum_{i=1}^{n-2} b_i \beta_i, b_i \geq 0\}.$$

W [1] zostało pokazane, że przestrzeń  $\mathcal{L}(K)$  może zostać podzielona na  $2^{n-2}$  rozłącznych obszarów w taki sposób, że każdy z nich może być opisany jako nieujemny ortant w bazie  $B_J = \{\beta_i, i \in J, \gamma_i, i \in L \setminus J\}$ , gdzie  $J$  jest pewnym podzbiorem zbioru  $L = \{1, 2, \dots, n-2\}$ . Zatem każdy element  $\mathbf{z}$  należący do  $\mathcal{L}(K)$  może być przedstawiony w następujący sposób

$$\mathbf{z} = \sum_{i \in J} b_i \beta_i + \sum_{i \in L \setminus J} c_i \gamma_i, \quad b_i > 0, c_i \geq 0.$$

Dla dowolnego zbioru  $J \subset L$ ,  $B_J$  jest bazą przestrzeni  $\mathcal{L}(K)$ , ponadto  $\beta_i, i \in J$  oraz  $\gamma_i, i \in L \setminus J$  są wzajemnie ortogonalne, zatem rzutem  $\mathbf{z}$  na  $K'$  jest wektor postaci

$$\mathbf{z}_{K'} = \sum_{i \in J} b_i \beta_i, b_i > 0$$

Podsumowując, dowolny wektor  $\mathbf{y}$  z przestrzeni  $\mathbb{R}^n$  można przedstawić w następującej postaci

$$\mathbf{y} = \mathbf{z} + \mathbf{y}_E = \sum_{i \in J} b_i \boldsymbol{\beta}_i + \sum_{i \in L \setminus J} c_i \boldsymbol{\gamma}_i + d_1 \boldsymbol{\gamma}_{n-1} + d_2 \boldsymbol{\gamma}_n, \quad b_i > 0, c_i \geq 0, d_1, d_2 \in \mathbb{R},$$

dla pewnego zbioru  $J \subset \{1, 2, \dots, n-2\}$ . W [1] zostało pokazane, że przedstawienie to jest jednoznaczne.

Wtedy rzut tego wektora na stożek  $K = \{\mathbf{A}\boldsymbol{\theta} \geq 0\}$  jest postaci

$$\hat{\boldsymbol{\theta}} = \sum_{i \in J} b_i \boldsymbol{\beta}_i + d_1 \boldsymbol{\gamma}_{n-1} + d_2 \boldsymbol{\gamma}_n.$$

Natomiast wektor reszt  $\hat{\boldsymbol{\rho}} = \mathbf{y} - \hat{\boldsymbol{\theta}}$  jest postaci

$$\hat{\boldsymbol{\rho}} = \sum_{i \in L \setminus J} c_i \boldsymbol{\gamma}_i.$$

**Przykład 2.** Rozważmy stożek z przykładu 1 i wektor obserwacji  $\mathbf{y}^T = (0; 3.1; 5.2; 6.8)$ . Na początek wyliczymy macierz rzutu oznaczoną w (2.1) jako  $\mathcal{E}(\mathcal{E}^T \mathcal{E})^{-1} \mathcal{E}^T$ .

$$\begin{aligned} \mathcal{E}(\mathcal{E}^T \mathcal{E})^{-1} \mathcal{E}^T &= \\ &= \begin{bmatrix} -1 & 3 \\ -1 & 1 \\ -1 & -1 \\ -1 & -1 \end{bmatrix} \left( \begin{bmatrix} -1 & -1 & -1 & -1 \\ 3 & 1 & -1 & -3 \end{bmatrix} \begin{bmatrix} -1 & 3 \\ -1 & 1 \\ -1 & -1 \\ -1 & -3 \end{bmatrix} \right)^{-1} \begin{bmatrix} -1 & -1 & -1 & -1 \\ 3 & 1 & -1 & -3 \end{bmatrix} = \\ &= \frac{1}{80} \begin{bmatrix} -1 & 3 \\ -1 & 1 \\ -1 & -1 \\ -1 & -3 \end{bmatrix} \begin{bmatrix} 20 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} -1 & -1 & -1 & -1 \\ 3 & 1 & -1 & -3 \end{bmatrix} = \\ &= \frac{1}{80} \begin{bmatrix} 56 & 32 & 8 & -16 \\ 32 & 24 & 16 & 8 \\ 8 & 16 & 24 & 32 \\ -16 & 8 & 32 & 56 \end{bmatrix}. \end{aligned}$$

Następnie wyznaczmy rzut  $\mathbf{y}_E$ .

$$\begin{aligned} \mathbf{y}_E &= \mathcal{E}(\mathcal{E}^T \mathcal{E})^{-1} \mathcal{E}^T \mathbf{y} = \\ &= \frac{1}{80} \begin{bmatrix} 56 & 32 & 8 & -16 \\ 32 & 24 & 16 & 8 \\ 8 & 16 & 24 & 32 \\ -16 & 8 & 32 & 56 \end{bmatrix} \begin{bmatrix} 0 \\ 3.1 \\ 5.2 \\ 6.8 \end{bmatrix} = \begin{bmatrix} 0.4 \\ 2.65 \\ 4.9 \\ 7.15 \end{bmatrix}. \end{aligned}$$

Wektor  $\mathbf{z}$ , który będziemy rzutować jest postaci  $\mathbf{z}^T = (-0.4; 0.45; 0.3; -0.35)$ . Baza mieszna w której wszystkie współrzędne tego wektora są dodatnie to  $B = (\boldsymbol{\gamma}_1, \boldsymbol{\gamma}_2, \boldsymbol{\gamma}_3, \boldsymbol{\beta}_4)$ , a poszczególne współrzędne wynoszą w przybliżeniu odpowiednio 0.4; 0.35; 0 i  $6.94 \cdot 10^{-18}$ . Zatem rzut wektora  $\mathbf{z}$  na stożek  $K$  jest równy

$$\mathbf{z}_K^T = 6.94 \cdot 10^{-18} \cdot (3; 1; -1; -3) = 10^{-18} \cdot (20.82; 6.94; -6.94; -20.82).$$

Zatem poszukiwany rzut wektora  $\mathbf{y}$  na stożek  $K$  jest postaci

$$\hat{\boldsymbol{\theta}}^T = \mathbf{y}_E^T + \mathbf{z}^T \approx \mathbf{y}_E^T = (0.4; 2.65; 4.9; 7.15). \diamond$$

### 3 Statystyka testowa i jej rozkład

#### 3.1 Lematy i oznaczenia

Na początek wprowadzimy kilka oznaczeń i udowodnimy dwa lematy z których skorzystamy w dalszej części rozważań. Zatem

$$\begin{aligned} C_{L \setminus J} &= \{\mathbf{y} \in \mathbb{R}^n : \mathbf{y} = \\ &= \sum_{i \in L \setminus J} b_i \boldsymbol{\gamma}_i + \sum_{i \in J} c_i \boldsymbol{\beta}_i + d_1 \boldsymbol{\gamma}_{n-1} + d_2 \boldsymbol{\gamma}_n, b_i > 0, c_i \geq 0, d_1, d_2 \in \mathbb{R}\} \end{aligned} \quad (3.1)$$

$$S_{L \setminus J} = \text{span}\{\boldsymbol{\gamma}_i, i \in L \setminus J\} \quad (3.2)$$

$$d = |L \setminus J| = n - 2 - |J| \quad (3.3)$$

Niech

$$\mathbf{A}_{L \setminus J} \quad (3.4)$$

oznacza macierz wymiaru  $n \times (n - 2)$  taką, że pierwsze  $d$  kolumn to wektory  $\boldsymbol{\gamma}_i, i \in L \setminus J$  natomiast pozostałe  $n - 2 - d$  kolumn to wektory  $\boldsymbol{\beta}_i, i \in J$ .

Niech wektor obserwacji  $\mathbf{y}$  ma  $n$ -wymiarowy rozkład normalny z nieznaną wartością oczekiwaną  $\mathbf{f} \in \Theta$  i znaną wariancją  $\sigma^2$ . Symbolem  $\mathcal{L}(\mathbf{f}, \mathbf{y})$  oznaczać będziemy funkcję wiarygodności

$$\mathcal{L}(\mathbf{f}, \mathbf{y}) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{f}\|^2 \right\}. \quad (3.5)$$

**Lemat 2.** Niech  $\mathbf{Z} = (Z_1, Z_2, \dots, Z_n)^T \sim N(\mathbf{0}, \mathbf{I})$  oraz niech  $\hat{\mathbf{Z}}$  będzie rzutem  $\mathbf{Z}$  na przestrzeń liniową  $S$  wymiaru  $d < n$ . Ponadto niech  $\mathbf{A}$  będzie rzeczywistą macierzą wymiaru  $m \times n$  taką, że każdy jej wiersz jest ortogonalny do przestrzeni  $S$  oraz  $m \leq n$  i  $\text{rank} \mathbf{A} = m$ . Wtedy rozkładem warunkowym  $\|\hat{\mathbf{Z}}\|^2$  pod warunkiem  $\mathbf{AZ} \geq 0$  jest rozkład  $\chi^2$  o  $d$  stopniach swobody.

*Dowód.* Niech  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$  będą wzajemnie ortonormalnymi wektorami w  $\mathbb{R}^n$  takimi, że wektory  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_d$  rozpinają przestrzeń  $S$ . Niech  $\mathbf{V}$  oznacza macierz taką, której poszczególne kolumny są kolejno wektorami  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$  oraz niech  $\mathbf{a} = (a_1, a_2, \dots, a_n)^T$ . Wektor  $\mathbf{Z}$  możemy zapisać jako  $\mathbf{Z} = \sum_{i=1}^n a_i \mathbf{v}_i$ , gdzie  $a_i = \langle \mathbf{v}_i, \mathbf{Z} \rangle$ . Stąd  $a_i, i = 1, 2, \dots, n$  są niezależnymi zmiennymi losowymi o standardowym rozkładzie normalnym, bo dla dowolnego  $i$  możemy napisać, że  $a_i = \mathbf{v}_i^T \mathbf{Z}$ , czyli  $\mathbf{a} = \mathbf{V}^T \mathbf{Z}$ . Stąd  $\mathbf{a} \sim N(\mathbf{0}, \mathbf{V}^T \mathbf{V})$ , gdzie  $\mathbf{V}^T \mathbf{V} = \mathbf{I}$ , bo wektory  $\mathbf{v}_1, \dots, \mathbf{v}_n$  są wzajemnie ortonormalne. Ponadto  $\hat{\mathbf{Z}} = \sum_{i=1}^d a_i \mathbf{v}_i$ . Wtedy  $\|\hat{\mathbf{Z}}\|^2 = a_1^2 + a_2^2 + \dots + a_d^2$  i dlatego zmienna losowa  $\|\hat{\mathbf{Z}}\|^2$  ma rozkład  $\chi^2$  o  $d$  stopniach swobody. Macierz  $\mathbf{V}$  możemy zapisać jako  $\mathbf{V} = [\mathbf{V}_1 | \mathbf{V}_2]$ , gdzie  $\mathbf{V}_1$  jest macierzą wymiaru  $n \times d$ , oznaczmy też przez  $\mathbf{a}^1$  wektor  $(a_1, a_2, \dots, a_d)^T$  a przez  $\mathbf{a}^2$  wektor  $(a_{d+1}, \dots, a_n)^T$ . Wtedy  $\mathbf{Z} = \mathbf{V}\mathbf{a} = \mathbf{V}_1 \mathbf{a}^1 + \mathbf{V}_2 \mathbf{a}^2$  a warunek  $\mathbf{A}\mathbf{Z} \geq 0$  możemy zapisać jako  $\mathbf{A}\mathbf{V}_1 \mathbf{a}^1 + \mathbf{A}\mathbf{V}_2 \mathbf{a}^2 \geq 0$ . Zauważmy, że z założenia o ortogonalności wierszy macierzy  $\mathbf{A}$  do przestrzeni  $S$  oraz konstrukcji macierzy  $\mathbf{V}$  dostajemy, że  $\mathbf{A}\mathbf{V}_1 = \mathbf{0}$  oraz  $\mathbf{a}^1, \mathbf{a}^2$  są niezależne. Zatem  $P(\|\hat{\mathbf{Z}}\|^2 \leq a | \mathbf{A}\mathbf{Z} \geq 0) = P(\|\mathbf{a}^1\|^2 \leq a | \mathbf{A}\mathbf{V}_2 \mathbf{a}^2 \geq 0)$ . Pokażemy teraz, że zbiór  $\{\omega \in \Omega : \mathbf{A}\mathbf{V}_2 \mathbf{a}^2(\omega) \geq 0\}$  jest niezerowej miary. Zmienna losowa  $\mathbf{A}\mathbf{V}_2 \mathbf{a}^2$  ma  $m$ -wymiarowy rozkład normalny  $N(\mathbf{0}, \Sigma)$ , gdzie  $\Sigma = \mathbf{A}\mathbf{V}_2 \mathbf{V}_2^T \mathbf{A}^T = \mathbf{A}\mathbf{A}^T$ , bo wiersze macierzy  $\mathbf{V}_2$  są wzajemnie ortonormalne. Ponadto z założeń dostajemy, że  $\text{rank} \mathbf{A}\mathbf{A}^T = m$ . Zatem nośnik zmiennej  $\mathbf{A}\mathbf{V}_2 \mathbf{a}^2$  zawrty jest w  $m$ -wymiarowej przestrzeni i nie jest zawarty w przestrzeni  $(m-1)$ -wymiarowej. Stąd i z symetrii rozkładu dostajemy, że  $P(\mathbf{A}\mathbf{V}_2 \mathbf{a}^2 \geq 0) = \frac{1}{2^{m-1}} \neq 0$ . Wtedy  $P(\|\mathbf{a}^1\|^2 \leq a | \mathbf{A}\mathbf{V}_2 \mathbf{a}^2 \geq 0) = \frac{P(\|\mathbf{a}^1\|^2 \leq a \wedge \mathbf{A}\mathbf{V}_2 \mathbf{a}^2 \geq 0)}{P(\mathbf{A}\mathbf{V}_2 \mathbf{a}^2 \geq 0)} = \frac{P(\|\mathbf{a}^1\|^2 \leq a)P(\mathbf{A}\mathbf{V}_2 \mathbf{a}^2 \geq 0)}{P(\mathbf{A}\mathbf{V}_2 \mathbf{a}^2 \geq 0)} = P(\|\mathbf{a}^1\|^2 \leq a) = P(\chi_d^2 \leq a)$  co należało dowieść.  $\square$

Idea powyższego lemat została zaczerpnięta z [2].

**Lemat 3.** Niech  $\mathbf{y} \in C_{L \setminus J}$  określonego wzorem (3.1) dla pewnego zbioru  $J \subset L = \{1, 2, \dots, n-2\}$  oraz niech  $a, b \in \mathbb{R}$ . Wtedy wektor  $\mathbf{y}' = \mathbf{y} + a\gamma_{n-1} + b\gamma_n$  należy do zbioru  $C_{L \setminus J}$  oraz wektory reszt  $\boldsymbol{\rho} = \mathbf{y} - \hat{\boldsymbol{\theta}}$  i  $\boldsymbol{\rho}' = \mathbf{y}' - \hat{\boldsymbol{\theta}}'$  są sobie równe.

*Dowód.* Jeśli  $\mathbf{y} \in C_{L \setminus J}$  to  $\mathbf{y}$  możemy zapisać jako  $\mathbf{y} = \sum_{i \in J} c_i \beta_i + \sum_{i \in L \setminus J} b_i \gamma_i + d_1 \gamma_{n-1} + d_2 \gamma_n$ ,  $b_i > 0, c_i \geq 0, d_1, d_2 \in \mathbb{R}$ . Wtedy  $\mathbf{y}' = \sum_{i \in J} c_i \beta_i + \sum_{i \in L \setminus J} b_i \gamma_i + (d_1 + a)\gamma_{n-1} + (d_2 + b)\gamma_n$ ,  $b_i > 0, c_i \geq 0, d_1, d_2 \in \mathbb{R}$ . Oczywiście  $d_1 + a, d_2 + b \in \mathbb{R}$  zatem  $\mathbf{y}' \in C_{L \setminus J}$ .

Wektor  $\boldsymbol{\rho}$  jest postaci  $\boldsymbol{\rho} = \sum_{i \in L \setminus J} b_i \gamma_i$ . Z postaci wektora  $\mathbf{y}'$  widzimy jednak, że  $\boldsymbol{\rho}' = \sum_{i \in L \setminus J} b_i \gamma_i = \boldsymbol{\rho}$ .  $\square$

Na koniec zostanie udowodnione twierdzenie nie mające bezpośredniego związku z postacią poszukiwanego test, pokazujące jednak pewną ciekawą własność rzutów wektora obserwacji  $\mathbf{y}$ .

**Twierdzenie 2.** *Rzuty wektora obserwacji  $\mathbf{y}$  na przestrzenie  $\text{span}\{\boldsymbol{\gamma}_i, i \in L \setminus J\}$ ,  $\text{span}\{\boldsymbol{\beta}_i, i \in J\}$  oraz  $\text{span}\{\boldsymbol{\gamma}_{n-1}, \boldsymbol{\gamma}_n\}$ , czyli wektory losowe  $\mathbf{y} - \hat{\boldsymbol{\theta}}$ ,  $\hat{\boldsymbol{\theta}} - \hat{\mathbf{y}}$  i  $\hat{\mathbf{y}}$  dla ustalonego zbioru  $J$  są stochastycznie niezależne.*

*Dowód.* Dla ustalonego stożka  $C_{L \setminus J}$  mamy  $\mathbf{y} - \hat{\boldsymbol{\theta}} = \sum_{i \in L \setminus J} b_i \boldsymbol{\gamma}_i$  oraz  $\hat{\boldsymbol{\theta}} - \hat{\mathbf{y}} = \sum_{i \in J} c_i \boldsymbol{\beta}_i$ . Z lematu 3 możemy założyć, że wektor  $\mathbf{y}$  ma rozkład  $N(0, \boldsymbol{\Sigma})$ . Niech  $S_1 = \text{span}\{\boldsymbol{\beta}_i, i \in J\}$ ,  $S_2 = \text{span}\{\boldsymbol{\gamma}_i, i \in L \setminus J\}$ ,  $S_3 = \text{span}\{\boldsymbol{\gamma}_{n-1}, \boldsymbol{\gamma}_n\}$ . Bazę każdej z tych przestrzeni można zortonormalizować tak, by  $S_1 = \text{span}\{\mathbf{v}_i, i \in J\}$ ,  $S_2 = \text{span}\{\mathbf{v}_i, i \in L \setminus J\}$ ,  $S_3 = \text{span}\{\mathbf{v}_{n-1}, \mathbf{v}_n\}$ , gdzie wektory  $\mathbf{v}_1, \dots, \mathbf{v}_n$  są wzajemnie ortonormalne. Niech  $V$  oznacza macierz, której kolumnami są wektory  $\mathbf{v}$ . Wektor  $\mathbf{y}$  możemy zapisać jako  $\mathbf{y} = \sum_{i=1}^n \langle \mathbf{v}_i, \mathbf{y} \rangle \mathbf{v}_i = \sum_{i=1}^n a_i \mathbf{v}_i$ . Analogicznie jak w dowodzie lematu 2.1 mamy, że  $\mathbf{a} = (a_1, a_2, \dots, a_n)^T \sim N(0, \mathbf{I})$ . Niech  $\mathbf{a}^1 = (a_1, \dots, a_{n-d-2})^T$ ,  $\mathbf{a}^2 = (a_{n-d-1}, \dots, a_{n-2})^T$ ,  $\mathbf{a}^3 = (a_{n-1}, a_n)^T$  oraz zapiszmy macierz  $V$  jako  $[V_1 | V_2 | V_3]$ . Wówczas  $\mathbf{y} = V_1 \mathbf{a}^1 + V_2 \mathbf{a}^2 + V_3 \mathbf{a}^3$  oraz  $\mathbf{y} - \hat{\boldsymbol{\theta}} = V_2 \mathbf{a}^2$ ,  $\hat{\boldsymbol{\theta}} - \hat{\mathbf{y}} = V_1 \mathbf{a}^1$  oraz  $\hat{\mathbf{y}} = V_3 \mathbf{a}^3$ . Wektory  $\mathbf{a}^1$ ,  $\mathbf{a}^2$  i  $\mathbf{a}^3$  są niezależne, zatem wektory  $V_1 \mathbf{a}^1$ ,  $V_2 \mathbf{a}^2$  oraz  $V_3 \mathbf{a}^3$  jako mierzalne funkcje tych wektorów również są niezależne dla ustalonego  $C_{L \setminus J}$ .  $\square$

### 3.2 Statystyka testowa

Lematy udowodnione w poprzednim paragrafie posłużą do wyznaczenia rozkładu statystyki testowej zaproponowanego testu opartego na ilorazie wiarygodności. Przypomnijmy, że problem testowania hipotez, którym się zajmujemy ma postać

$$H_0: f(x) = ax + b \quad \text{vs.} \quad H_1: f \in \mathcal{F}, \quad (3.6)$$

gdzie  $\mathcal{F}$  jest klasą funkcji wypukłych.

Niech  $\hat{\mathbf{y}}$  oznacza estymator regresji liniowej, czyli rzut wektora danych  $\mathbf{y}$  na przestrzeń rozpinaną przez wektory  $\boldsymbol{\gamma}_{n-1}, \boldsymbol{\gamma}_n$ ,  $\hat{\boldsymbol{\theta}}$  oznacza estymator regresji wypukłej, będący rzutem wektora obserwacji na odpowiedni stożek wypukły. Ponadto oznaczmy przez  $R_0 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \|\mathbf{y} - \hat{\mathbf{y}}\|^2$  oraz  $R_1 = \sum_{i=1}^n (y_i - \hat{\theta}_i)^2 = \|\mathbf{y} - \hat{\boldsymbol{\theta}}\|^2$ .

**Uwaga 1.** Powyższe estymatory  $\hat{\mathbf{y}}$  i  $\hat{\boldsymbol{\theta}}$ , jako elementy minimalizujące kwadrat normy błędu, czyli elementy optymalne w sensie aproksymacji średniokwadratowej, wyznaczone zostały przy zastosowaniu metody najmniejszych kwadratów. Jednak przy założeniu normalności rozkładu wektora obserwacji estymatory wyznaczone tą metodą są tożsame z estymatorami wyznaczonymi przy pomocy metody największej wiarygodności. Rozważmy ogólny model  $\mathbf{x} = \phi(\mathbf{x}) + \boldsymbol{\varepsilon}$ , gdzie  $\phi(\mathbf{x})$  jest poszukiwanym parametrem, a wektor błędów  $\boldsymbol{\varepsilon}$  ma  $n$ -wymiarowy rozkład normalny

$N(\mathbf{0}, \sigma^2 \mathbf{I})$  ze znaną wariancją. Stosując metodę najmniejszych kwadratów dostajemy, że estymatorem  $\phi(\mathbf{x})$  jest wektor  $\hat{\phi}(\mathbf{x})$  minimalizujący wyrażenie  $\sum_{i=1}^n (\mathbf{x}_i - \phi(\mathbf{x})_i)^2$ , gdzie  $\mathbf{x}_i, \phi(\mathbf{x})_i$  oznaczają kolejne współrzędne odpowiednio wektora  $\mathbf{x}$  i  $\phi(\mathbf{x})$ . Stosując metodę największej wiarygodności przy założeniu normalności rozkładu wektora  $\mathbf{x}$  będziemy maksymalizować funkcję wiarygodności postaci  $L(\phi(\mathbf{x}), \mathbf{x}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\{-\frac{1}{2\sigma^2}(\mathbf{x}_i - \phi(\mathbf{x})_i)^2\} = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (\mathbf{x}_i - \phi(\mathbf{x})_i)^2\}$ . Maksymalizacja tej funkcji jest równoważna maksymalizacji jej logarytmu  $l(\phi(\mathbf{x}), \mathbf{x}) = \ln(2\pi\sigma^2)^{-\frac{n}{2}} - \frac{1}{2\sigma^2} \sum_{i=1}^n (\mathbf{x}_i - \phi(\mathbf{x})_i)^2$  co przy założeniu znajomości wariancji prowadzi do równoważnego zagadnienia minimalizacji wyrażenia  $\sum_{i=1}^n (\mathbf{x}_i - \phi(\mathbf{x})_i)^2$ , czyli tego samego, które otrzymaliśmy stosując metodę najmniejszych kwadratów. Zatem przy założeniu normalności rozkładu wektora obserwacji  $\mathbf{x}$  estymatory uzyskiwane obiema metodami są sobie równe.

W rozważanym problemie hipotezę zerową możemy utożsamić z pewną podprzestrzenią parametrów  $\Theta_0 \subset \Theta$  a alternatywę z podprzestrzenią  $\Theta_1 \subset \Theta$ . Określmy funkcję

$$l(\mathbf{y}) = \frac{\sup_{\mathbf{f} \in \Theta} \mathcal{L}(\mathbf{f}, \mathbf{y})}{\sup_{\mathbf{f} \in \Theta_0} \mathcal{L}(\mathbf{f}, \mathbf{y})}.$$

Oczywiście dla dowolnego  $\mathbf{y} \in \mathbb{R}^n$  mamy, że  $l(\mathbf{y}) \in [1, +\infty)$ , ponadto duże wartości  $l(\mathbf{y})$  powinny sugerować, że hipoteza zerowa nie jest poprawna.

**Definicja 5.**<sup>2</sup> Testem hipotezy  $H_0: \mathbf{f} \in \Theta_0$  przy alternatywie  $H_1: \mathbf{f} \in \Theta_1$  opartym na ilorazie wiarygodności na poziomie istotności  $\alpha$  nazywamy funkcję

$$\phi(\mathbf{y}) = \begin{cases} 1 & \text{gdy } l(\mathbf{y}) > c \\ \xi & \text{gdy } l(\mathbf{y}) = c \\ 0 & \text{gdy } l(\mathbf{y}) < c \end{cases},$$

gdzie stałe  $c, \xi$  są tak dobrane by rozmiar testu nie przekraczał  $\alpha$ .

Zatem zgodnie z definicją 5 możemy rozważyć zbiór odrzucenia  $C$  w naszym problemie (3.6) postaci

$$\begin{aligned} C = \phi^{-1}(\{1\}) &= \left\{ \mathbf{y} \in \mathbb{R}^n : \frac{\sup_{\mathbf{f} \in \Theta} \mathcal{L}(\mathbf{f}, \mathbf{y})}{\sup_{\mathbf{f} \in \Theta_0} \mathcal{L}(\mathbf{f}, \mathbf{y})} > c \right\} =^3 \\ &= \left\{ \mathbf{y} \in \mathbb{R}^n : \frac{(2\pi\sigma^2)^{-\frac{n}{2}} \exp\{-\frac{1}{2\sigma^2} \|\mathbf{y} - \hat{\boldsymbol{\theta}}\|^2\}}{(2\pi\sigma^2)^{-\frac{n}{2}} \exp\{-\frac{1}{2\sigma^2} \|\mathbf{y} - \hat{\mathbf{y}}\|^2\}} > c \right\} = \end{aligned}$$

<sup>2</sup>Definicja podana za J. Bartoszewicz *Wykłady ze statystyki matematycznej*, PWN, Warszawa, 1996.

<sup>3</sup>przejście możliwe dzięki uwadze 1

$$\begin{aligned}
&= \left\{ \mathbf{y} \in \mathbb{R}^n : \exp \left\{ \frac{1}{2\sigma^2} \left( \|\mathbf{y} - \hat{\mathbf{y}}\|^2 - \|\mathbf{y} - \hat{\boldsymbol{\theta}}\|^2 \right) \right\} > c \right\} \\
&= \left\{ \mathbf{y} \in \mathbb{R}^n : \frac{\|\mathbf{y} - \hat{\mathbf{y}}\|^2 - \|\mathbf{y} - \hat{\boldsymbol{\theta}}\|^2}{\sigma^2} > c' \right\} = \\
&= \left\{ \mathbf{y} \in \mathbb{R}^n : \frac{R_0 - R_1}{\sigma^2} > c' \right\}.
\end{aligned}$$

Zatem będziemy poszukiwać przy założeniu prawdziwości hipotezy zerowej  $H_0$  rozkładu statystyki testowej postaci

$$M = \frac{R_0 - R_1}{\sigma^2}.$$

**Twierdzenie 3.** *Przy założeniu prawdziwości hipotezy zerowej postawionego problemu mamy*

$$P(M \leq a) = \sum_{d=0}^{n-2} P(\chi_{n-d-2}^2 \leq a) P(D = d),$$

gdzie  $\chi_0^2 \equiv 0$ , czyli rozkładem statystyki testowej  $M$  jest mieszany rozkład  $\chi^2$  z pewnymi wagami  $P(D = d)$ .

*Dowód.* Z lematu 3 możemy bez straty ogólności założyć, że  $f(x) = 0$  skąd  $\mathbf{y} = \boldsymbol{\varepsilon}$ . Dla dowolnej realizacji wektora  $\boldsymbol{\varepsilon} \in \mathbb{R}^n$  oznaczmy przez  $L \setminus J$  taki zbiór indeksów, że  $\boldsymbol{\varepsilon} \in C_{L \setminus J}$ . Zatem wyrażenie  $R_1 = \|\mathbf{y} - \hat{\boldsymbol{\theta}}\|^2$  zależy poprzez  $\hat{\boldsymbol{\theta}}$  od wyboru zbioru  $J$ , który jest losowy, różne wartości wektora błędu  $\boldsymbol{\varepsilon}$  mogą umieścić wektor danych  $\mathbf{y}$  w różnych zbiorach  $C_{L \setminus J}$ . Zauważmy jednak, że z jednoznaczności przedstawienia wektora w zbiorze  $C_{L \setminus J}$  zdarzenia postaci  $\{\mathbf{y} \in C_{L \setminus J}\}$ ,  $J \in \mathcal{P}(L)$ , gdzie  $\mathcal{P}(L)$  oznacza zbiór potęgowy zbioru  $L$ , są wzajemnie rozłączne oraz ich suma stanowi całą przestrzeń zdarzeń elementarnych. Ponadto prawdopodobieństwa tych zdarzeń są niezerowe. Możemy zatem skorzystać z twierdzenia o prawdopodobieństwie całkowitym.

$$P(M \leq a) = \sum_{J \in \mathcal{P}(L)} P(M \leq a | \mathbf{y} \in C_{L \setminus J}) P(\mathbf{y} \in C_{L \setminus J}).$$

Na początku rozważmy jakie są rozkłady odpowiednio  $\frac{R_1}{\sigma^2}$  oraz  $\frac{R_0}{\sigma^2}$  przy założeniu prawdziwości hipotezy zerowej i przy ustalonym zbiorze  $J$ .

Niech  $\hat{\boldsymbol{\varepsilon}}$  będzie rzutem wektora  $\boldsymbol{\varepsilon}$  na przestrzeń  $S_{L \setminus J}$ . Zauważmy, że macierz  $\mathbf{A}_{L \setminus J}$  można zapisać jako  $[\mathbf{A}_1 | \mathbf{A}_2]$ , gdzie macierz  $\mathbf{A}_1$  jest wymiaru  $n \times d$ . Zatem kolumny macierzy  $\mathbf{A}_1$  rozpinają  $S_{L \setminus J}$ , natomiast kolumny macierzy  $\mathbf{A}_2$  są ortogonalne do przestrzeni  $S_{L \setminus J}$ . Dodatkowo, gdy  $\boldsymbol{\varepsilon} \in C_{L \setminus J}$ , zachodzi  $\mathbf{A}_1^T \boldsymbol{\varepsilon} \geq 0$  oraz  $\mathbf{A}_2^T \boldsymbol{\varepsilon} \geq 0$ . Stąd na mocy lematu 2 dostajemy, że rozkładem warunkowym  $\frac{\|\hat{\boldsymbol{\varepsilon}}\|^2}{\sigma^2}$  przy zadanym  $J$  jest rozkład  $\chi^2$  o  $d$  stopniach swobody, gdzie  $d = |L \setminus J|$ . Jako że  $R_1 = \|\hat{\boldsymbol{\rho}}\|^2$

a przy założeniu prawdziwości hipotezy zerowej  $\|\hat{\boldsymbol{\rho}}\|^2$  jest równe  $\|\hat{\boldsymbol{\varepsilon}}\|^2$  przy ustalonym zbiorze  $J$ , otrzymujemy, że jeśli hipoteza zerowa  $\boldsymbol{\theta} \in \text{span}\{\boldsymbol{\gamma}_{n-1}, \boldsymbol{\gamma}_n\}$  jest prawdziwa to rozkładem warunkowym  $\frac{R_1}{\sigma^2}$  przy ustalonym zbiorze  $J$  jest  $\chi_d^2$ , gdzie  $d = |L \setminus J|$ .

Zmienna losowa  $\frac{R_0}{\sigma^2}$  jest rzutem wektora danych  $\mathbf{y}$  na przestrzeń rozpinaną przez wektory  $\boldsymbol{\beta}_i, \boldsymbol{\gamma}_j, i \in J, j \in L \setminus J$  a zatem ma rozkład  $\chi^2$  o  $n - 2$  stopniach swobody.

Rozważmy teraz wyrażenie  $R_0 - R_1$ . Skorzystamy tutaj z następujących własności normy- dla dowolnych wektorów  $\mathbf{x}, \mathbf{y}$  i dowolnej liczby rzeczywistej  $a$  mamy, że  $\|\mathbf{x} + \mathbf{y}\|^2 = \|\mathbf{x}\|^2 + \|\mathbf{y}\|^2 + 2\langle \mathbf{x}, \mathbf{y} \rangle$  oraz  $\|a\mathbf{x}\|^2 = a^2\|\mathbf{x}\|^2$ .

Zatem dla ustalonego zbioru  $J$  dostajemy, że

$$\begin{aligned} R_0 - R_1 &= \|\mathbf{y} - \hat{\mathbf{y}}\|^2 - \|\mathbf{y} - \hat{\boldsymbol{\theta}}\|^2 = \left\| \sum_{i \in L \setminus J} b_i \boldsymbol{\gamma}_i + \sum_{i \in J} c_i \boldsymbol{\beta}_i \right\|^2 - \left\| \sum_{i \in L \setminus J} b_i \boldsymbol{\gamma}_i \right\|^2 = \\ &= \sum_{i \in L \setminus J} b_i^2 \|\boldsymbol{\gamma}_i\|^2 + \sum_{i \in J} c_i^2 \|\boldsymbol{\beta}_i\|^2 + 2 \sum_{\substack{i \in L \setminus J \\ j \in J}} b_i c_j \langle \boldsymbol{\gamma}_i, \boldsymbol{\beta}_j \rangle + 2 \sum_{\substack{i, j \in L \setminus J \\ i \neq j}} b_i b_j \langle \boldsymbol{\gamma}_i, \boldsymbol{\gamma}_j \rangle + \\ &\quad + 2 \sum_{\substack{i, j \in J \\ i \neq j}} c_i c_j \langle \boldsymbol{\beta}_i, \boldsymbol{\beta}_j \rangle - \sum_{i \in J} b_i^2 \|\boldsymbol{\gamma}_i\|^2 - 2 \sum_{\substack{i, j \in J \\ i \neq j}} b_i b_j \langle \boldsymbol{\gamma}_i, \boldsymbol{\gamma}_j \rangle = \\ &= \sum_{i \in J} c_i^2 \|\boldsymbol{\beta}_i\|^2 + 2 \sum_{\substack{i, j \in J \\ i \neq j}} c_i c_j \langle \boldsymbol{\beta}_i, \boldsymbol{\beta}_j \rangle = \left\| \sum_{i \in J} c_i \boldsymbol{\beta}_i \right\|^2 = \|\hat{\mathbf{y}} - \hat{\boldsymbol{\theta}}\|^2, \end{aligned}$$

bo  $\langle \boldsymbol{\gamma}_i, \boldsymbol{\beta}_j \rangle = 0$  dla  $i \neq j$ . Otrzymaliśmy zatem rzut wektora  $\boldsymbol{\varepsilon}$  na przestrzeń  $\text{span}\{\boldsymbol{\beta}_i, i \in J\}$  dla ustalonego zbioru  $J$ . Na mocy lematu 2 rzut ten przeskalowany o wariancję ma rozkład  $\chi^2$  o  $n - d - 2$  stopniach swobody. Liczba stopni swobody w tym rozkładzie zależy jedynie od liczności zbioru  $L \setminus J$ , natomiast nie zależy bezpośrednio od dokładnej jego postaci. Niech zatem  $D$  będzie zmienną losową reprezentującą licznosc zbioru  $L \setminus J$ . Otrzymujemy wtedy, że rozkładem  $\frac{R_0 - R_1}{\sigma^2}$  pod warunkiem  $D = d$  jest  $\chi^2$  o  $n - d - 2$  stopniach swobody, co należało pokazać.  $\square$

Wartości prawdopodobieństw  $P(D = d), d = 0, 1, \dots, n - 2$  są wyliczane na podstawie względnych objętości zbiorów  $C_{L \setminus J}, J \in \mathcal{P}(L)$ . Prawdopodobieństwo, że  $\mathbf{y} \in C_{L \setminus J}$ , gdy hipoteza zerowa jest prawdziwa, jest równoważne prawdopodobieństwu, że wektor losowy o  $n$ -wymiarowym standardowym rozkładzie normalny wpada do zbioru  $C_{L \setminus J}$ . Wyznaczenie wartości  $P(D = d)$  jest dla dużych  $n$  bardzo trudne i najczęściej stosuje się w tym celu pewne przybliżenia numeryczne.

## 4 Podsumowanie

W pracy została zaprezentowana konstrukcja testu statystycznego przeznaczonego do testowania problemu wyboru krzywej regresji następującej postaci

$$H_0: f(x) = ax + b \quad \text{vs.} \quad H_1: f \in \mathcal{F},$$



gdzie  $\mathcal{F}$  jest klasą funkcji wypukłych.

W wyniku rzutowania wektora obserwacji na wielościenne stożek wypukły powstały jako rezultat wymogu wypukłości funkcji  $f$  otrzymano estymator regresji wypukłej, który pozwolił wyznaczyć rozkład statystyki testowej następującej postaci

$$P(M \leq a) = \sum_{d=0}^{n-2} P(\chi_{n-d-2}^2 \leq a) P(D = d),$$

będący mieszanym rozkładem  $\chi^2$  z wagami  $P(D = d)$ . Prawdopodobieństwa  $P(D = d)$  wyznaczone są na podstawie względnych objętości zbiorów  $C_{L \setminus J}$ ,  $J \in \mathcal{P}(L)$ . Przedstawione rozważania zostały oparte przede wszystkim o wyniki przedstawione przez M. C. Meyer w pracy [2].

W powyższej pracy zostały przeprowadzone przez autora dowody lematów 1 oraz 3 oraz twierdzenia 2, a także dodane zostały własne przykłady 1 i 2. Przeformulowano także twierdzenie 2 głównie uzupełniając założenia o założenie o rządzie macierzy  $\mathbf{A}$ , uzasadniając niezerowość prawdopodobieństwa warunku i doprecyzowując rozkład wektora  $\mathbf{a}$ . Dodano także uzasadnienie stosowalności wyznaczonych estymatorów w rozważanym problemie (uwaga 1) i doprecyzowano dowód twierdzenia 3 głównie o dokładną postać wyrażenia  $R_0 - R_1$ .

*Kropka nie oznacza końca zdania.*

*Ona daje możliwość coraz to lepszej kontynuacji.*

## Bibliografia

- [1] Fraser D.A.S., Massam H., *A Mixed Primal- Dual Bases Algorithm for Regression under Inequality Constraints. Application to Concave regression*, Scand J. Statist, **16** 65-74, 1989
- [2] Meyer Mary C., *A test for linear vs convex regression function using shape-restricted regression*, Stanford University, Technical Report No. 2001-20, sierpień 2001